

Confiabilidad y poder predictivo

Poder predictivo → RMSE

Modelo 1: Regresión lineal múltiple

Modelo 2: Regresión logística múltiple

Para comprobar confiabilidad de un modelo RLM:

1. La variable de respuesta debe ser cuantitativa y continua, sin restricciones para su variabilidad
2. Los predictores deben ser cuantitativos o dicotómicos (de ahí la necesidad de variables indicadoras para manejar más de dos niveles)
3. Los predictores deben tener algún grado de variabilidad (su varianza no debe ser igual a cero). En otras palabras, no pueden ser constantes
4. Cada predictor debe estar relacionado linealmente con la respuesta
5. La distribución de los residuos debe ser cercana a la normal centrada en cero
6. La variabilidad de los residuos debe ser aproximadamente constante (homocedasticidad)
7. Los residuos deben ser independientes entre sí
8. No debe existir multicolinealidad. Esto significa que no deben darse relaciones lineales fuertes (coeficientes de correlación altos) entre dos o más predictores
9. Las estimaciones de los coeficientes del modelo no deben estar alterados por unas pocas observaciones influyentes

Herramientas para comprobar las condiciones anteriores:

1. Literatura
2. Literatura
3. Literatura
4. `residualPlots()`
5. `residualPlots()`
6. `ncvTest()`
7. `durbinWatsonTest()`
8. `vif(modelo)`
9. `influencePlot()`

Para comprobar confiabilidad de un modelo RLOG:

1. Debe existir una relación lineal entre los predictores y la respuesta transformada
2. Los residuos deben ser independientes entre sí
3. Multicolinealidad entre los predictores (se aborda igual que RLM, con el factor de inflación de la varianza o la tolerancia)
4. Información incompleta, que se produce cuando no contamos con observaciones suficientes para todas las posibles combinaciones de predictores, en especial para algún nivel de una variable categórica.
5. Separación perfecta, que ocurre cuando no hay superposición entre las clases (es decir, como vimos, cuando los predictores separan ambas clases completamente)

6. Las estimaciones de los coeficientes del modelo no están dominadas por casos sobreinfluyentes

Herramientas para comprobar las condiciones anteriores:

1. Usar los gráficos de residuos vistos para RLM, provistos por la función `residualPlots()` del paquete `car`, agregando el argumento `fitted = FALSE`. El mismo paquete `car` permite revisar linealidad usando gráficos de residuos parciales, por medio de la función `crPlots(model, terms = ~ .)`
2. Usar prueba de Durbin-Watson implementada en la función `durbinWatsonTest()` del paquete `car`
3. Obtener factores de inflación de varianza utilizando la función `vif(modelo)`
4. Se recomienda contar con 10 a 15 observaciones por cada predictor numérico y nivel de las variables categóricas
5. A
6. Usar gráficos de influencia con la función `influencePlot(modelo)` del paquete `car`