

Decisiones Cap 12

12.1 Remuestreo

¿Cuándo se usa?

1. Cuando necesitamos inferir sobre parámetros distintos a la media o la proporción
2. Cuando no se cumplen supuestos sobre la distribución de los datos (como normalidad u homocedasticidad) o el conocimiento de parámetros poblacionales (como la varianza)
3. Muestras reducidas o insuficientes para asegurar el cumplimiento del teorema del límite central

¿Qué es?

Consiste en extraer repetidamente muestras de un conjunto original para obtener información sobre la población de origen:

1. Estimaciones de la variabilidad de un estadístico muestral
2. Construir intervalos de confianza
3. Docimar hipótesis

Supuestos para su aplicación

1. Muestra original representativa de la población para asegurar validez de las remuestras → Esto se logra mediante el muestreo aleatorio simple (semillas)
2. Observaciones independientes en la muestra original, no hay influencia entre las filas (observaciones) de los datos → Esto se rompe por ejemplo si tomamos más de una muestra en diferentes instantes de tiempo.

12.1.1 Bootstrapping

Pasos para su aplicación:

1. Crear una gran cantidad R de remuestras que se obtengan a partir de muestreo con reposición y que tengan el mismo tamaño que la muestra original
2. Calcular estadístico de interés bootstrap para cada una de las remuestras, los cuales forman la distribución bootstrap
3. A partir de la distribución bootstrap se obtiene información útil como forma, centro y variabilidad de la distribución muestral del estadístico

Ojo: La distribución bootstrap está centrada en el estadístico de la muestra y no en el parámetro de la población, por lo cual existe un sesgo

12.1.2 Bootstrapping para una muestra

Buscamos armar un intervalo de confianza para el parámetro de la población asociado al estimador de la distribución bootstrap

Alternativa 1: En base a una fórmula estudiada

Alternativa 2: En base a cuantiles críticos definidos por el nivel de significación

Alternativa 3: BCa, en caso de que el resultado de los 2 anteriores tenga diferencias importantes

Función para implementar bootstrap

1. `boot(data, statistic, R)` → genera la distribución bootstrap
2. `boot.ci(boot.out, conf, type)` → calcula intervalo de confianza

data: el conjunto de datos. En caso de matrices y `data.frame`, se considera cada fila como una observación con múltiples variables (columnas).

statistic: función que se aplica a los datos y devuelve un vector con el (o los) estadístico(s) de interés.

R: cantidad de remuestreos bootstrap.

boot.out: objeto de clase `boot`, generado por la función

conf: nivel de confianza ($1 - \alpha$). `boot()`.

type: string o vector que indica los tipos de intervalo de confianza a construir ("norm" para el basado en la distribución Z, "perc" para el basado en los percentiles y "bca" para el método BCa).

Si se obtienen 3 intervalos de confianza parecidos con [boot.ci](#) para los 3 type, entonces se puede concluir que con x% de confianza (depende de alpha) el parámetro buscado se encuentra entre esos valores

(Script 12.1) Aplica distribución bootstrap sobre un vector numérico

(Script 12.2) Obtiene mismo resultados que script 12.1 pero ordenados en una matriz

12.1.3 Bootstrapping para dos muestras independientes

Para dos muestras independientes potencialmente provenientes de poblaciones distintas, de tamaños n_A y n_B :

1. Fijar cantidad R de repeticiones bootstrap
2. En cada repetición: a) hacer un remuestreo con reposición de tamaño n_A a partir de la muestra MA. b) hacer un remuestreo con reposición de tamaño n_B a partir de la muestra MB. c) calcular el estadístico de interés con las remuestras conseguidas.
3. Construir el intervalo de confianza para el estadístico de interés a partir de la distribución bootstrap generada.

`shapiro.test()` para comprobar normalidad:

H_0 : no existe normalidad

H_1 : los datos siguen una distribución normal

$p < 0.05$ implica rechazar la hipótesis nula aceptando la normalidad