

¿Cómo trabajar datos y tomar muestras?

Lectura de datos

Formato CSV estándar

Delimitador de columnas: coma ,

Delimitador de decimales: punto .

Función ideal: `read.csv("archivo.csv")`

Formato CSV latino/europeo

Delimitador de columnas: punto y coma ;

Delimitador de decimales: coma ,

Función ideal: `read.csv2("archivo.csv")`

Formato delimitado por tabulaciones

Delimitador de columnas: `\t`

Delimitador de decimales:

Función ideal: `read.delim("archivo.txt")` o `read.table("archivo.txt", header = TRUE, sep = "\t")`

Funciones para toma de muestras

1. `sample()` (RBase)

Diseñada para trabajar sobre vectores atómicos (columnas)

Parámetros:

`x` → vector de datos

`size` → tamaño de la muestra a obtener

`replace` → boolean. Define si el muestreo es con o sin reposición

`prob` → vector de probabilidades

2. `slice_sample()` (dplyr/tidyverse)

Permite obtener muestras aleatorias de datos tabulares (`data.frame`)

`data` → datos de entrada

`n` → número de observaciones a extraer

`prop` → alternativa a `n`, que permite extraer cierta proporción o porcentaje del total de filas

`replace` → boolean. Permite extraer filas con reemplazo si lo requiere el método estadístico

¿Qué hacer si los datos tienen casillas NA?

1. Descartar filas incompletas de manera global

```
# Limpia todas las filas que tengan al menos un NA en todo el dataframe
datos_limpios <- subset(datos, complete.cases(datos))
# O en formato tidyverse:
datos_limpios <- datos |> filter(complete.cases(.))
```

2. Ignorar NA en cálculos específicos

```
# Si calculas una media o varianza de una columna con datos faltantes
mean(datos$columna, na.rm = TRUE)
```

¿Cómo agrego columnas a partir de otras?

Función mutate():

```
library(dplyr)
```

```
datos <- datos |>
  mutate(
    # 1. Crear una columna numérica calculada a partir de otras
    IMC = Weight / (Height / 100)^2,

    # 2. Crear una columna categórica condicional (ej. clasificar en base a un umbral)
    EN = ifelse(IMC >= 23.2, "sobrepeso", "no sobrepeso"),

    # 3. Forzar obligatoriamente a factor las variables categóricas (vital para modelos y gráficos)
    EN = factor(EN, levels = c("no sobrepeso", "sobrepeso"))
  )
```

¿Cómo aplicar filtros?

```
# Filtrar por condición numérica y de texto simultáneamente
datos_filtrados <- datos |>
  filter(n.nodos >= 50 & sexo == "Femenino")
```